

FAESA

Projeto Integrador III - Aplicações de Ciência de Dados
Entrega 3 (C3) - Produto Final / MVP e Documentação Técnica

Documentação Técnica

Análise de Evasão Escolar na Grande Vitória (ES)

Professor: Howard Cruz Roatti

Curso: Ciência da Computação

Equipe

Felipe Rodrigues Barzilai
Gabriel Rodrigo Lapa Rocha
Ricardo da Silva Junior
Hevellyn Monteiro Medeiros
Wagner dos Santos Cristo

Grande Vitória - ES

2024/2025

Documentação Técnica

Análise de Evasão Escolar na Grande Vitória (ES)

Entrega 3 (C3) - Produto Final / MVP e Documentação Técnica

1. Visão Geral

Este projeto tem como objetivo analisar fatores educacionais associados à evasão escolar na região da Grande Vitória, composta pelos municípios de Vitória, Vila Velha, Serra e Cariacica, utilizando dados públicos disponibilizados pelo Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira (INEP).

A análise dá destaque ao Ensino Médio, etapa em que o abandono escolar se mostrou mais elevado no conjunto analisado. Algumas etapas do notebook, especialmente os modelos de regressão, utilizam uma taxa média geral de abandono calculada a partir de colunas do Ensino Fundamental e do Ensino Médio. Essa escolha deve ser considerada na interpretação dos resultados.

A solução foi desenvolvida como um Produto Mínimo Viável (MVP), com foco em gerar evidências iniciais sobre padrões de abandono escolar e apoiar discussões futuras sobre permanência estudantil e políticas públicas educacionais.

2. Enquadramento do Tema e Sociedade Impactada

O projeto se enquadra na área de direitos humanos e impacto social, pois a permanência escolar está diretamente relacionada ao direito à educação, à redução de desigualdades e à ampliação de oportunidades acadêmicas e profissionais.

A sociedade impactada pelo projeto inclui:

- estudantes do Ensino Médio da Grande Vitória;
- escolas públicas e privadas da região analisada;
- gestores escolares e equipes pedagógicas;
- secretarias e órgãos responsáveis por políticas educacionais;
- pesquisadores e demais interessados em indicadores de evasão escolar.

A comunidade impactada não participou diretamente do desenvolvimento do projeto, mas foi identificada a partir da relevância social do problema analisado.

3. Objetivos

3.1 Objetivo Geral

Investigar padrões e fatores educacionais associados ao abandono escolar na Grande Vitória, com destaque para o Ensino Médio, utilizando dados oficiais do INEP e técnicas de ciência de dados.

3.2 Objetivos Específicos

- identificar diferenças nas taxas de abandono entre os municípios analisados;
- comparar indicadores de abandono entre etapas de ensino;
- comparar a distribuição das taxas de abandono entre redes de ensino;
- avaliar a relação entre taxa de aprovação e taxa de abandono;
- aplicar regressão linear simples e regressão linear múltipla para análise dos fatores associados ao abandono;
- gerar evidências que possam contribuir para estudos futuros sobre permanência escolar.

4. Escopo do MVP

O MVP entregue concentra-se em uma análise exploratória e estatística inicial. O escopo implementado no notebook contempla:

- carregamento e integração de bases do INEP;
- filtragem geográfica para municípios da Grande Vitória;
- cálculo de taxas médias de abandono por etapa de ensino;
- análise por município e por dependência administrativa;
- correlação de Pearson entre aprovação e abandono;
- regressão linear simples;
- regressão linear múltipla com taxa de aprovação e dependência administrativa.

Modelos não lineares, como Random Forest Regressor, não fazem parte da versão implementada da documentação corrigida. Eles são tratados apenas como possibilidade de trabalho futuro.

5. Arquitetura da Solução

O fluxo de processamento do projeto é composto pelas seguintes etapas:

1. Dados INEP
2. Filtragem geográfica
3. Tratamento e integração dos dados
4. Cálculo de indicadores de abandono e aprovação
5. Análise exploratória dos dados (EDA)
6. Correlação de Pearson
7. Regressão Linear Simples
8. Regressão Linear Múltipla
9. Interpretação dos resultados e limitações

6. Base de Dados

6.1 Fonte dos Dados

Os dados utilizados foram obtidos no portal oficial do INEP.

6.2 Arquivos Utilizados

- microdados_ed_basica_2024.csv
- tx_rend_escolas_2024.xlsx

6.3 Municípios Analisados

- Vitória
- Vila Velha
- Serra
- Cariacica

6.4 Variáveis Utilizadas

Variável	Descrição
CO_ENTIDADE	Código identificador da escola.
NO_MUNICIPIO	Município em que a escola está localizada.
SG_UF	Unidade federativa.
TP_DEPENDENCIA	Dependência administrativa da escola.
1_CAT_FUN_*	Colunas de taxa de aprovação do Ensino Fundamental.
1_CAT_MED_*	Colunas de taxa de aprovação do Ensino Médio.

3_CAT_FUN_*	Colunas de taxa de abandono do Ensino Fundamental.
3_CAT_MED_*	Colunas de taxa de abandono do Ensino Médio.

7. Pré-processamento dos Dados

Antes da análise, os dados passaram pelas seguintes etapas de preparação:

- seleção das colunas necessárias dos microdados escolares;
- filtragem das escolas localizadas no Espírito Santo e nos municípios da Grande Vitória;
- padronização do campo CO_ENTIDADE para permitir a integração entre as bases;
- integração dos microdados escolares com a base de taxas de rendimento por meio de merge;
- conversão das colunas de taxas educacionais para formato numérico com `pd.to_numeric(errors="coerce")`;
- tratamento de valores inválidos por conversão para NaN;
- cálculo de variáveis derivadas, como `taxa_abandono_fund`, `taxa_abandono_med`, `taxa_abandono_total` e `taxa_aprovacao_total`.

A variável `taxa_abandono_total` foi calculada como média das colunas de abandono do Ensino Fundamental e do Ensino Médio. Por isso, quando essa variável é usada nos modelos, a interpretação corresponde ao abandono médio geral da escola, e não exclusivamente ao Ensino Médio.

8. Indicadores e Métricas Utilizadas

Indicador/Métrica	Uso no projeto
Taxa média de abandono no Ensino Fundamental	Comparar o abandono no Ensino Fundamental com o Ensino Médio.
Taxa média de abandono no Ensino Médio	Identificar a etapa mais crítica quanto à evasão escolar.
Taxa média de abandono por município	Comparar padrões entre Vitória, Vila Velha, Serra e Cariacica.
Taxa média de abandono por rede de ensino	Analisar diferenças de distribuição entre dependências administrativas.
Taxa média de aprovação	Avaliar a relação entre desempenho escolar e abandono.
Correlação de Pearson	Medir a direção e intensidade da associação entre aprovação e abandono.
R ²	Avaliar a proporção da variação explicada pelos modelos de regressão.
MAE	Medir o erro médio absoluto na regressão linear múltipla.

9. Análise Exploratória dos Dados (EDA)

A análise exploratória buscou compreender o comportamento dos dados e identificar padrões iniciais relacionados ao abandono escolar.

9.1 Comparação entre Ensino Fundamental e Ensino Médio

O notebook indica que a taxa média de abandono no Ensino Médio foi de aproximadamente 1,13%, enquanto a taxa média no Ensino Fundamental foi de aproximadamente 0,21%. Assim, no conjunto analisado, o abandono médio no Ensino Médio foi cerca de 5,4 vezes maior que no Ensino Fundamental.

Esse resultado reforça o Ensino Médio como etapa crítica para ações de permanência escolar.

9.2 Comparação por Município

Foram analisadas diferenças nas taxas médias de abandono entre Vitória, Vila Velha, Serra e Cariacica. A comparação por município permite identificar variações territoriais e levantar hipóteses sobre desigualdades locais, embora o projeto não utilize variáveis socioeconômicas para testar essas hipóteses.

9.3 Comparação por Rede de Ensino

A análise por dependência administrativa utiliza a variável TP_DEPENDENCIA, mapeada para as categorias Federal, Estadual, Municipal e Privada. As visualizações indicam maior variabilidade nas escolas públicas quando comparadas à rede privada.

Como o gráfico por rede utiliza taxa_abandono_total, a interpretação correta é de abandono médio geral por rede de ensino, e não abandono exclusivamente do Ensino Médio.

10. Correlação de Pearson

Foi aplicada a Correlação de Pearson para avaliar a relação entre taxa_aprovacao_total e taxa_abandono_total.

10.1 Objetivo

Verificar se escolas com maiores taxas médias de aprovação tendem a apresentar menores taxas médias de abandono escolar.

10.2 Interpretação

O notebook interpreta a associação como negativa moderada. Isso significa que, no conjunto analisado, escolas com maiores taxas de aprovação tendem a apresentar menores taxas de abandono. Essa relação é associativa e não deve ser interpretada como causalidade direta.

11. Regressão Linear Simples

11.1 Objetivo

Avaliar a associação entre a taxa média de aprovação e a taxa média de abandono escolar.

11.2 Variáveis

Tipo	Variável
Variável independente	taxa_aprovacao_total
Variável dependente	taxa_abandono_total

11.3 Modelo Utilizado

Foi utilizado o modelo LinearRegression() da biblioteca scikit-learn.

11.4 Resultados e Interpretação

A regressão linear simples indicou coeficiente negativo, aproximadamente -0,131, sugerindo que aumentos na taxa média de aprovação estão associados à redução da taxa média de abandono escolar.

O modelo apresentou R^2 aproximado de 0,17. Portanto, cerca de 17% da variação da taxa média de abandono foi explicada pela taxa média de aprovação. O resultado indica uma associação relevante para análise, mas também mostra que a evasão depende de outros fatores não contemplados no modelo.

12. Regressão Linear Múltipla

12.1 Objetivo

Investigar simultaneamente a influência da taxa média de aprovação e da dependência administrativa da escola sobre a taxa média de abandono.

12.2 Variáveis Utilizadas

- taxa_aprovacao_total;
- TP_DEPENDENCIA_2, representando a rede estadual após transformação em variáveis dummies;
- TP_DEPENDENCIA_3, representando a rede municipal após transformação em variáveis dummies;
- TP_DEPENDENCIA_4, representando a rede privada após transformação em variáveis dummies.

12.3 Tratamento das Variáveis Categóricas

A variável TP_DEPENDENCIA foi transformada por meio de `pd.get_dummies(..., drop_first=True)`, permitindo que a dependência administrativa fosse usada no modelo de regressão.

12.4 Avaliação

Foram utilizadas as métricas R^2 e MAE.

12.5 Resultados e Interpretação

A regressão linear múltipla apresentou baixo poder explicativo, com R^2 próximo de 0 no conjunto de teste. Isso indica que as variáveis utilizadas não são suficientes para explicar adequadamente a variação da taxa média de abandono escolar.

Apesar disso, a etapa é válida como análise inicial, pois permite testar a contribuição conjunta da aprovação e da dependência administrativa. O resultado reforça a necessidade de incorporar variáveis adicionais em versões futuras do projeto.

13. Resultados Consolidados

- O Ensino Médio apresentou taxa média de abandono superior à observada no Ensino Fundamental.
- A taxa média de abandono no Ensino Médio foi aproximadamente 5,4 vezes maior que a do Ensino Fundamental no conjunto analisado.
- Foram observadas diferenças entre os municípios analisados.
- As escolas públicas apresentaram maior variabilidade nas taxas médias de abandono quando comparadas à rede privada.
- A relação entre taxa média de aprovação e taxa média de abandono foi interpretada como negativa moderada.
- A regressão linear simples apresentou R^2 aproximado de 0,17.
- A regressão linear múltipla apresentou baixo poder explicativo, com R^2 próximo de 0.
- Os resultados indicam que a evasão escolar é multifatorial e não pode ser explicada apenas por aprovação e dependência administrativa.

14. Métricas de Impacto Social do MVP

Além das métricas técnicas dos modelos, o projeto considera métricas de impacto relacionadas ao uso dos resultados para apoiar a tomada de decisão educacional.

Métrica de impacto	Forma de medição
Identificação de etapa crítica	Comparação entre taxa média de abandono do Ensino Fundamental e do Ensino Médio.
Identificação de diferenças territoriais	Comparação da taxa média de abandono entre municípios da Grande Vitória.

Priorização de redes de ensino	Análise da distribuição da taxa média de abandono por dependência administrativa.
Geração de evidências educacionais	Produção de gráficos, indicadores e interpretações no notebook do projeto.
Apoio a estudos futuros	Registro das limitações e recomendação de novas variáveis para melhorar a explicação do fenômeno.

15. Limitações

- O projeto utiliza exclusivamente dados educacionais disponíveis nas bases analisadas.
- Não foram incorporados indicadores socioeconômicos, demográficos ou familiares.
- As hipóteses sobre desigualdade social, trabalho precoce ou apoio familiar não foram testadas diretamente.
- Parte dos modelos utiliza taxa_abandono_total, que combina colunas de Ensino Fundamental e Ensino Médio.
- O número de variáveis explicativas é reduzido.
- A regressão linear múltipla apresentou baixo poder explicativo.
- Os resultados indicam associação entre variáveis, mas não comprovam causalidade.

16. Trabalhos Futuros

- incorporar indicadores socioeconômicos, como renda, vulnerabilidade social e características territoriais;
- incluir dados demográficos e familiares, quando disponíveis;
- separar com maior rigor os modelos voltados exclusivamente ao Ensino Médio;
- avaliar modelos não lineares, como Random Forest Regressor, apenas após ampliação das variáveis explicativas;
- comparar resultados em diferentes anos para verificar evolução temporal da evasão;
- desenvolver visualizações interativas para facilitar a interpretação dos indicadores por gestores e comunidade acadêmica.

17. Reprodutibilidade do Projeto

O projeto é executado por meio do notebook `analise_evasao_es_completa.ipynb`. Para reproduzir a análise, os arquivos de dados devem estar na mesma pasta do notebook, conforme orientado no repositório do projeto.

- Executar o notebook em ambiente Jupyter ou Google Colab;
- garantir que os arquivos `microdados_ed_basica_2024.csv` e `tx_rend_escolas_2024.xlsx` estejam disponíveis;
- executar as células na ordem apresentada;
- validar os gráficos, métricas e tabelas gerados durante a execução.

18. Informações de Entrega da C3

Esta documentação corresponde à Entrega 3 (C3), referente ao produto final/MVP, demonstração completa da solução e documentação técnica do Projeto Integrador III.

Item	Informação
Repositório GitHub do projeto	[inserir link do repositório GitHub da equipe]
Vídeo de apresentação da C3	[inserir link do vídeo disponibilizado no GitHub]
Arquivo principal da análise	<code>analise_evasao_es_completa.ipynb</code>

Os links do GitHub e do vídeo devem ser preenchidos com os endereços finais utilizados na entrega oficial ao professor.

19. Conclusão

A análise demonstra que o abandono escolar na Grande Vitória apresenta diferenças relevantes entre etapas de ensino, municípios e redes de ensino. O Ensino Médio se destacou como etapa mais crítica, apresentando taxa média de abandono superior à observada no Ensino Fundamental.

Também foi observada associação negativa entre aprovação e abandono escolar, indicando que escolas com maiores taxas médias de aprovação tendem a apresentar menores taxas médias de abandono. No entanto, os modelos de regressão mostraram capacidade explicativa limitada, reforçando que a evasão escolar é um fenômeno complexo e multifatorial.

Como o MVP utiliza um conjunto reduzido de variáveis, recomenda-se ampliar a base analítica em trabalhos futuros, incorporando indicadores socioeconômicos, demográficos e territoriais. Essa ampliação pode melhorar a compreensão do fenômeno e fortalecer o uso dos resultados como apoio à formulação de políticas de permanência escolar.

20. Referências

BRASIL. Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira (INEP). Disponível em: <https://www.gov.br/inep>

PEDREGOSA, F. et al. Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research, 2011.

MCKINNEY, Wes. Python for Data Analysis. O'Reilly Media, 2022.

HUNTER, John D. Matplotlib: A 2D Graphics Environment. Computing in Science & Engineering, 2007.

WASKOM, Michael. Seaborn: Statistical Data Visualization. Journal of Open Source Software, 2021.